

第二届“厚粲杯”全国大学生 心理与认知智能测评挑战赛

参赛计划书

题 目 人机协同情境下个体对 AI 监督校准与合规执
行力的交互式情境测验开发

赛 道 测验赛道

主 题 认知与能力

填 报 日 期 2026 年 7 月 9 日

大赛组委会

二零二六年四月

预期方案

一、选题的研究意义、国内外研究现状分析

1 文献综述

1.1 现实痛点与研究切入

当前企业的文案撰写、数据报告、客服答复等环节已经大量引入生成式 AI。据麦肯锡 (McKinsey, 2023a) 研究报告, 生成式 AI 预计可自动执行当前知识型工作者 60% 至 70% 的工作时间, 展现出极高的渗透力。然而, 高效率背后潜藏着巨大的交付风险。麦肯锡同期的全球调研 (McKinsey, 2023b) 显示, 高达 56% 的受访企业将“输出不准确”(即未经充分核验即对外发布) 视为生成式 AI 的首要风险, 但目前仅有 32% 的企业正在积极采取措施缓解这一风险。这种“高采用率、低控制力”的组织失衡, 迫切需要科学的测评工具来识别员工在 AI 辅助情境下是否能保持必要的风险警觉与责任意识。然而, 现有人才测评体系缺乏针对“人机协作能力”的有效量化手段。本测验应运而生, 为 AI 治理和人才风险管理提供量化方案。

随着生成式 AI 不断进入知识型工作场景, 人机协作已经逐渐成为工作常态。但很多组织面临的问题并不只是技术本身, 而是员工在使用 AI 时容易出现“信任失衡”: 有些人过度相信 AI, 不做核查就直接采用结果, 可能带来错误和风险; 另一些人则过度怀疑 AI, 导致工作效率下降。从心理学角度来看, 这种问题本质上与“元认知监控”有关, 也就是个体是否能够正确判断“什么时候可以相信 AI、什么时候需要进一步核查” (Nelson & Narens, 1990)。同时, 人们还需要在有限的时间和注意力下, 对 AI 输出进行必要的监督和风险判断。因此, 一个重要的问题是: 在 AI 辅助工作情境中, 个体是否具备合理使用 AI、主动核查信息并遵守规范的能力? 这种能力又是否能够通过标准化测验进行有效评估?

1.2 理论基础

在人机交互研究中, AI 通常被看作一种辅助决策工具。人在使用 AI 时, 不只是接受结果, 还需要判断 AI 输出是否可靠, 并最终做出自己的决策。Lee 和 See (2004) 指出, 由于 AI 并不是完全准确的系统, 有时也会出现错误, 因此人们应该对 AI 保持“适度信任”, 也就是根据 AI 实际表现来调整自己的依赖程度。但在现实中, 人们对 AI 的信任往往容易出现偏差。如果过度相信 AI, 就可能出现自动化偏差, 即不加判断地接受 AI 结果; 如果过度怀疑 AI, 则可能产生算法厌恶, 即使 AI 整体表现较好, 人们也不愿意继续使用它。这两种情况都会影响工作效果。

Mosier 和 Skitka (1996) 的研究发现, 当人们使用辅助系统时, 往往会减少主动思考和监督, 更容易依赖系统判断。在这种情况下, 容易出现两类错误: 一种是委托错误, 即 AI 已经出错, 但人

仍然继续采纳它的建议；另一种是遗漏错误，即 AI 没有提示风险，人也没有主动发现问题。Dietvorst 等人(2015)则发现，一旦 AI 出现错误，人们又容易走向另一个极端，对算法产生过度不信任。即使算法整体上比人的判断更准确，个体也可能因为一次错误而拒绝继续使用它。

这些研究共同揭示：人类对 AI 的依赖属于“信任—不信任”的连续结构。**个体天然倾向于降低主动监督并盲信 AI，但 AI 犯错后又可能过度否定。**高水平的人机互动应表现为个体主动校准对 AI 的依赖与信任(Huang & Li, 2024)。本研究将这种“校准”表现界定为一种可测量的认知-执行能力。

1.3 测量工具的空白与本研究定位

然而，当前测量工具主要采用自陈式量表(如人机自动化信任量表，Cui et al., 2025)，这类工具更接近于测量个体对 AI 的典型态度或主观倾向，而非最大表现能力。在招聘筛选等高评价压力情境下，自陈量表容易受到社会称许性偏差影响，难以预测真实工作表现。企业更关心的是：当员工在真实工作中面对“**AI 结果可能正确也可能出错**”的情况时，能否在**有限的时间和注意力**条件下，合理使用 AI，并对最终结果承担责任。因此，这种能力需要通过贴近实际工作任务的情境化行为测验来进行评估。从组织心理学视角来看，企业在人才选拔中越来越重视工作样本测验与情境判断测验（SJT）的预测效度，因为这类测验更接近真实工作中的“最大表现”，能够比自陈问卷更有效地预测实际行为(Sackett et al., 1988; McDaniel et al., 2007)。因此，在 AI 协作背景下开发基于真实任务的行为测验，具有明确的人才测评价值。

当前研究存在两大空白：(1)缺乏在真实工作任务情境下、可用于组织实践的测验工具；(2)缺乏基于真实人机交互过程数据的行为测量机制。此外，在组织应用层面，AI 使用中的风险识别与合规执行是风险控制的重要一环(Tabassi, 2023)，合规执行即个体对隐蔽违规风险的识别敏感度，及生成合规替代方案的行为能力，将合规边界管理纳入 AI 协作能力测评具有明确的现实意义。

2 研究意义

本研究首次将“面向 AI 协作的个体监督校准与合规执行力”界定为一种**最大表现类认知-执行能力**，通过贴近真实工作的情境化任务，客观评估个体在 AI 辅助工作中的风险识别能力，以及对 AI 信任程度的调整能力。相比传统的自我报告问卷，这种行为测验能够更真实地反映个体在实际任务中的表现，也为人机协作研究提供了一种新的心理测量工具。

在**理论层面**，本研究将个体对 AI 的依赖行为从抽象的认知研究转化为可测量的能力构念。同时，研究尝试将生成式 AI 直接应用到心理测评过程中，通过“人与 AI 互动—记录行为过程—转化为心理指标”的方式，探索心理测量与人工智能结合的新路径。这种方法融合了元认知监控、

风险判断和执行控制等心理学机制，也为智能时代的人才评估提供了新的理论参考。

在**实践层面**，企业迫切需要识别员工在真实任务中的监督校准与合规能力。这样才能减少因盲目相信 AI、信息泄露或不当承诺等问题带来的质量和安全风险。本测验可以为企业招聘和面试提供直观、可解释的数据参考，也能为员工入职后的 AI 使用培训和能力提升提供依据，从而帮助企业提高 AI 时代的风险管理水平。

二、研究目标、研究内容和拟解决的关键问题

1 研究目标

本研究希望回答一个核心的心理学问题：**当 AI 成为工作伙伴时，个体如何在不确定信任中保持理性的元认知控制？**

具体来说，本项目计划开发一套**标准化、可量化，并且贴近真实工作场景的能力测验**，用于评估个体在 AI 辅助工作中的监督、信任校准和合规管理能力，并应用于企业招聘和人才评估。

与传统的 AI 使用态度或技能测量不同，本研究关注的是：在“AI 先生成内容、人类负责最终交付”的工作模式下，个体能否在 AI 结果可能正确也可能错误的情况下，依然承担最终责任，并主动进行核查和风险控制。

2 研究内容

2.1 构念定义

本研究的构念是：**面向 AI 协作的个体监督校准与合规执行力**。其操作性定义是：在 AI 输出正确性不确定的情境下，在时间与资源受限的条件中，个体能否动态调整对 AI 的依赖程度，主动进行关键核查，并最终形成正确、可追溯且合规的交付成果。

该能力包含三个子维度：

第一，**校准式依赖能力**。其底层的心理学机制是元认知监控与信任的动态调整，即个体需要根据对当前任务状态的判断，动态决定是否继续核查、修正或采纳已有信息。在操作层面上，它指个体能够根据 AI 的实际表现和任务风险，灵活调整自己的信任程度。具体表现为：当 AI 输出正确时，能高效采纳以提升效率；当 AI 输出错误时，能敏锐识别并及时修正，从而避免“盲目相信”或“过度怀疑”这两个极端。

第二，**核验监督能力**。其底层的心理学机制是风险判断与注意力资源的分配。在操作层面上，它反映了个体在认知资源（如精力和时间）有限的情况下，准确识别关键风险点并进行有效核查的能力。该维度强调对风险优先级的理性判断，以及如何合理配置核查资源。

第三，**合规边界执行力**。其底层的心理学机制是执行控制与伦理警觉。在操作层面上，它指

个体在复杂的业务语境中，识别出那些隐蔽违规风险的敏感度。这些风险包括隐私数据泄露、越权做出承诺、引用过期条款等。除了能发现问题，该维度还强调个体主动生成合理、合规的替代表达的具体执行力。

上述能力均通过客观行为指标进行量化。校准式依赖能力主要通过 **AI 正确题中的高效采纳与 AI 错误题中的关键纠错**来体现；核验监督能力主要通过受测者是否在**数据或事实风险点**触发核对并**落实到最终修订**来体现；合规边界执行力则通过其对**红线敏感度**及生成**合规替代文本**的质量来体现。




图 1 测验构念理论框架图

2.2 测验开发

2.2.1 整体结构

本测验采用基于 Web 端网页的沉浸式情境模拟（Situational Simulation）形式。受测者需登录标准的人机协作工作台，模拟真实的组织办公环境。测验界面由任务要求区、证据材料区和具有生成式 AI 助手的交互编辑区共同构成。




图 2 测评链路全景架构与数据流向图

结合图 2 的四层架构，受测者在 22-25 分钟的完整测评流程中，其数据流向如下：

1. 任务输入层（被试在做什么）：受测者在电脑前依次完成两个模块。首先进入**模块 A（AI 协作交付任务）**，受测者需利用初始分配的 20 点精力点数，自主决定何时打开证据材料核对信息，或调用 AI 进行对照核查。随后进入**模块 B（微决策题）**，针对突发的 10 类人机冲突或风险场景进行快速下一步行动抉择。

2. 行为日志层（后台记录什么）：当受测者在平台上进行操作时，后台 API 与日志模块将实时、无感地记录其全过程行为特征，包括：证据材料点击时序、在关键风险处的停留时长、AI 生成建议采纳率、精力点数消耗轨迹以及文本最终修订幅度。

3. 指标提取层（数据如何加工）：测验结束时，系统将提交的最终文本与日志特征结合。一方面，通过“AI 辅助初评+人工 Rubric 复核”判定交付文本在事实、合规维度上的正确性；另一方面，利用 RES 分段函数公式（详见 2.2.4），结合其正确率与剩余点数计算出资源分配效率指标，以此将行为过程转化为测量指标。

4. 结果输出层（产出什么报告）：最终，系统将模块 A 与模块 B 的得分按照 8:2 的权重折算为 100 分制总分，并输出三大核心维度的**雷达图**。同时，报告将根据其在正确和错误情境下的具体采纳率与纠错率，输出其专属的**人机协作行为画像**（盲信风险型、过疑低效型、校准良好型），为企业招聘和人才盘点提供直观、可解释的量化依据。

这一全景架构确保了本测验在设计上“理论有支撑、过程有记录、指标有定义、计分有依据”，实现了测评链路的闭环统一。

2.2.2 模块 A：AI 协作交付任务

模块 A 为测验核心，由六道工作样本测验题构成，覆盖数据口径分析、制度合规处理与对外沟通三类知识型岗位高频情境，每类两题。

在**数据分析情境**中，受测者需根据运营数据撰写简报结论。例如，在某题中，证据材料显示转化率下降，但 AI 初稿错误表述为“转化率同步提升”。若受测者未核查关键指标而直接采纳，则构成典型“委托错误”；若在 AI 本身正确的情况下仍反复否定并改写，则可能表现为过疑倾向。通过此类题目，可以区分不同个体的信任校准水平。

在**制度合规情境**中，AI 可能在对外说明文本中隐含未脱敏信息或越权承诺。受测者需识别潜在红线，并选择或生成合规表达。例如，在某题中 AI 给出包含完整手机号示例的回复，受测者若未进行去标识化处理即提交，将在合规维度严重失分。

在**对外沟通情境**中，AI 可能生成过度承诺或不符合公司政策的赔偿方案。受测者需在客户满意度与组织风险之间进行边界校准，体现合规执行能力。

为避免“核查越多越高分”的误测，本模块引入**“精力点数”机制**。受测者拥有固定资源，打开证据材料或使用深度核查功能均需消耗点数，点数耗尽后无法继续获取信息。该机制模拟真实工作中有限认知资源情境，使能力差异体现为风险识别与资源分配策略，而非简单核查次数。

为确保精力点数机制在不同受测者之间可比且可复现，本研究将在系统中固定点数消耗规则并在测验开始前统一说明：受测者全程共享初始精力点数（20 点），打开证据材料全文或触发深度核查功能将消耗点数，点数耗尽后仍可继续编辑与提交，但无法再打开证据材料全文或使用“对照核查”等深层信息获取功能，从而形成真实的注意力与时间成本约束。精力点数消耗表以固定表实现（详见下文 5.4 附表）。模块 A 的评分维度与评分实施方式见下文 2.2.4。

模块A题库示例							
题号	题材类型	AI初稿状态	风险等级	交付物要求（示例）	关键核对点（含证据位置示例）	红线点（隐蔽）	正确修正策略锚点（用于合规判分）
A1	数据口径类	基本正确	低	80 - 120字；必须含“结论+建议+风险”；不得编造数字	K1：本周UV=128,400（证据包：数据表《周度漏斗》R2C2）；K2：转化率=2.35%（R2C5）；次要：环比=+0.12pct（R2C6）；次要：口径=“仅含自然流量”（页眉说明）	红线：AI草稿可能把“自然流量”写成“全量”（口径越界）	若证据仅支持自然流量，必须写清口径边界；不得扩展到全量结论
A2	制度合规类	基本正确	中	以内部口径给出“可做/不可做+依据条款+替代方案”；100字内	K1：条款编号=“隐私政策第4.2条”（证据：制度《数据处理规范》P3）；K2：最小必要原则表述=“仅收集完成服务所必需信息”（P3第2段）；次要：保留期限=“180天”（P4）	红线：AI草稿可能把“180天”写成“永久保存”或遗漏“最小必要”限制	明确“最小必要+期限”，并给替代方案（如改用脱敏/聚合字段）
A3	对外沟通类	隐蔽泄露/越权承诺	高	客服话术：解释+方案+时效边界；不得泄露敏感信息；110字内	K1：可提供的方案=“退货/换货二选一”（证据：售后政策P2）；K2：处理时效=“3-5个工作日”（P3）；次要：需材料=“照片+订单号”（P2）	红线：AI草稿可能带出客户手机号/地址（在证据包备注栏）；或承诺“当天退款”“100%赔付”	先去标识化（删除手机号/地址等），再承诺降级；按政策给时效区间；必要时引用标准口径

图 3 模块 A 题库示例

2.2.3 模块 B：监督策略微决策（Micro-SJT）

模块 B 采用**微型情境判断测验形式**。系统呈现“任务背景+AI 回复”的简化情境，受测者需在四个行为选项（最优解、次优解、无效解、风险解）中选择下一步行动。该模块强调决策倾向与风险敏感度的快速判断，与模块 A 形成结构互补，用于提升结构效度与测量稳定性。模块 B 的计分规则与效率指标口径见下文 2.2.4。

模块B题库示例							
题号	场景类型	呈现给候选人的信息形态	核心风险点	最优下一步动作（得2分）	次优动作（得1分）	错误/风险动作（0分或-1）	主要对应维度
B1	数字核对	AI给出周报结论，含具体转化率与环比	数字可能错/口径可能混	触发“对照证据核查”或“打开证据包定位关键数字”（二选一，按你们界面按钮）	“列出依据”但随后需核对关键数字	直接提交；或只做“压缩字数”	核验监督、校准
B2	证据不足边界	AI把相关当因果给出原因	证据不足被写死	触发“标注不确定性（保守表达）”	打开证据包看是否有因果证据	直接提交；或继续追问AI但不回证据	证据边界
B3	政策条款对照	AI引用条款号但未给出处	仍依据/错条款	触发“列出依据（标注条款位置）”	打开证据包搜索条款号	直接提交；或只压缩结构	核验监督
B4	SLA越权承诺	AI话术出现“24小时必解决/保证赔付”	越权承诺	触发“合规修正策略：B承诺降级 + C引用标准口径”	打开证据包查SLA再改写	直接提交；或A去标识化（不解决越权）	合规边界

图 4 模块 B 题库示例

2.2.4 计分方式与行为指标探索

本测验满分为 100 分，最终计分采用权重折算。模块 A 原始满分为 60 分（6 题×10 分），模块 B 原始满分为 20 分（10 题×2 分）。为体现两模块的重要性差异，模块 A 按 80/60 线性折算至 0–80 分，模块 B 按 20/20 折算至 0–20 分，总分为两者折算后之和。

值得注意的是，为评估个体在有限时间与注意力条件下的最优决策能力，本测验将“精力点数”作为资源分配效率评分指标，并将其纳入模块 A 的最终计分模型。

在真实组织情境中，盲目的全盘核对虽然可能降低错误率，但会带来高昂的时间与精力成本。因此，高水平的监督者应具备“精准核验”的能力：在保证交付质量的前提下，把有限的核验资源投入到高风险点上。为此，系统在模块 A 中结合受测者的交付质量与剩余精力点数，计算资源效益得分（Resource Efficiency Score, RES），用于表征其在“质量—资源”权衡下的认知资源配置效率。

设任务基础得分为 S，初始精力点数为 E₀，剩余精力点数为 E_{rem}，效益调节系数为 γ（本测验设定为 0.1），并设定任务基础得分的及格线为 S_{pass}。RES 的计算采用如下分段规则：

$$RES = \begin{cases} S, & S < S_{pass} \\ S(1 + \gamma \cdot \frac{E_{rem}}{E_0}), & S \geq S_{pass} \end{cases}$$

该计分机制遵循“双向约束”的逻辑。首先是绩效优先约束：当受测者的任务基础得分未达到及格线（表明存在盲信漏报或关键错误未纠正）时，不提供任何资源效益加分，以防止“不作

为”的盲信者仅凭保留点数获得高分。其次是效率激励约束：当受测者任务基础得分达到及格线后，系统依据其剩余精力点数占比 $\frac{E_{rem}}{E_0}$ ，提供有限幅度的效率奖励（奖励上限为 γ ，即最高不超过基础得分的一定比例），以反映其在保证交付质量的同时实现选择性核验与资源优化配置的能力。

模块 A 采用**统一 Rubric 对每题进行 0–10 分评定**。评分同时覆盖交付正确性与一致性、证据边界表达、合规边界执行以及资源分配策略。为保证评分稳定性，本项目采用“AI 辅助初评+人工 Rubric 复核”的组合路径：

(1)**AI 参与初评阶段**。系统调用大语言模型对提交的文本进行自动分析，识别关键字段一致性(数字/日期/条款编号等是否与证据材料匹配)、是否存在明显合规风险(如包含完整手机号、过度承诺等)。AI 根据预设规则输出初步判定结果，并标注疑似错误位置。

(2)**人工复核与最终评分**。人工评分员依据统一 Rubric 对 AI 初评结果进行复核，重点关注证据边界表达质量、合规修正的合理性以及资源分配策略的有效性。在研发阶段通过双人评分与仲裁校准评分口径，确保评分者间一致性(ICC)达到 0.85 以上。

模块A评分rubric			
维度	分值	得分条件（写死口径，便于训练评分员）	典型扣分触发（建议写进评分指南）
正确性/一致性	0 - 4	以出题时的关键核对点K1/K2两项为准：两项都正确=4分；仅1项正确=2分；两项都错/缺失=0分。若出现“核心结论与证据方向相反”可直接判0分。	关键数字/日期/条款号与证据不一致；把证据不存在的数写入交付物；把口径边界扩写为全量结论。
证据边界表达	0 - 2	2分：能明确限定依据范围（如“基于当前证据包/现有数据口径”），并对未证实部分使用保守表述（如“可能/需进一步核实/建议补充X数据”）；1分：偶有边界词但仍夹带确定性因果或结论跳跃；0分：把推测写成事实/把相关当因果/无依据给出确定原因。	“一定因为…”但证据无因果；“显然/必然/保证”等绝对化表达；把备注栏推断为用户欺诈等定性。
合规边界	0 - 3	3分：识别红线并完成合规替代（去标识化/承诺降级/引用标准口径），且对外可用不过激；2分：识别并修正但仍略不稳妥（边界不够/口径不够标准）；1分：意识到风险但修正不彻底或处理过激导致不可用；0分（硬规则）：出现敏感字段残留/越权承诺/引用过期政策且当作现行/明显不当表述。	任何可识别个人信息残留（手机号/地址/身份证/客户备注名+联系方式等）；“保证24小时解决/保证赔付”；引用旧版SLA/政策版本号；歧视性措辞。
资源分配策略	0 - 1	1分：点数主要投入在高风险题或高风险字段，且带来有效修订（关键点纠错/红线消除）；0分：明显错配（低风险正确题过度核对耗点数；高风险题几乎不核对且最终错/越界）。	高风险题不打开证据包导致关键错误进入交付；在A1/A5等低风险正确题多轮“对照核查”但文本无关键改动。

图 5 模块 A 评分 rubric

模块 B 采用**四选一的下一步行动判断题**，最优解计 2 分、次优解计 1 分、无效解计 0 分、风险解计 0 分，并记录作答用时作为效率指标。

除用于计分的预设证据外，本测验依托全过程行为日志还具备进一步探索多类行为指标的研究空间。例如，可在“信息获取—核验—修订—提交”的链路上，探索证据材料访问的时序与停留结构、AI 按钮使用的序列模式、精力点数在不同风险题与不同字段上的投入轨迹、以及文本采

纳与修订幅度等。

2.2.5 结果报告

测验结束后，系统综合模块 A 与模块 B 得分，生成三个子维度分数，并根据校准式依赖能力与核验监督能力的组合情况，形成三类能力画像：盲信风险型、过疑低效型与校准良好型。报告将提供行为特征说明与风险提示，增强结果的可解释性。

2.3 施测并验证信效度

测验开发完成后，将进行样本施测与统计分析。（1）信度方面，采用内部一致性与重测稳定性检验测验的稳定程度。（2）研究将结合探索性因子分析（EFA）与维度间相关分析，对测验的潜在结构进行初步探索，重点考察各行为指标是否能够形成相对稳定的维度聚类。（3）效标效度方面，将测验得分与工作样本测验评分及 AI 相关培训后绩效提升幅度进行相关分析，以检验其预测效度与实际应用价值。

3 拟解决的关键问题

本研究旨在解决以下四个在心理测量学与人机交互交叉领域的核心问题：

- 1. 在测量人机协作表现时，如何有效区分个体的主观依赖态度与实际监督能力，并防止因“盲目核对”导致的分数水分？
- 2. 作为一种新兴的人机协作特质，该能力在个体的深层心理结构中处于什么位置？其底层的维度结构（如校准依赖、核验监督、合规把关）该如何进行实证验证？
- 3. 如何在高度模拟真实工作的动态交互环境中采集数据，并将被试复杂的人机互动行为（如文本修改、证据阅读）转化为符合心理测量学要求的客观指标？
- 4. 生成式大语言模型（LLM）的输出天然具有随机性与非确定性，如何化解这一特征与心理测量学“标准化、可复现、跨个体可比”要求之间的张力？

三、拟采用的方法手段与技术路线

针对问题一，研究拟引入资源约束机制与对称性情境设计。为了防止被试通过全面核查来刷分，测验中设计了“精力点数”限制。被试在查看背景资料或使用深度核查工具时，都需要消耗点数；当点数用完后，就无法继续获取更多信息。这样的设计可以模拟真实工作中的时间和精力限制，促使被试主动判断哪些内容更值得优先核查。同时，测验会同时设置“AI 结果正确”和“AI 结果错误”两类情境，并保持数量平衡。研究会综合考察被试对错误内容的纠正能力，以及对正确内容的合理采纳能力，从而减少测量偏差。

针对问题二，研究将通过多维度结构设计和统计模型来验证测验的有效性。在理论上，研究

将该能力拆解为校准式依赖能力、核验监督能力与合规边界执行力三个子维度。同时，还会把测验结果与传统的人机信任问卷进行比较，分析两者之间的相关性，以验证本测验的收敛效度和区分效度，并突出其作为“最大表现测验”的独特性。

针对问题三，研究致力于解决如何将“复杂人机交互过程转化为客观心理测量指标”这一学术难点。为此，本项目依据图 2 所确立的测评全景架构，在自研网页端沉浸式平台中部署了无感行为日志记录技术。我们不再仅仅依赖最终的文本交付物进行评价，而是建立一条操作证据链：

1. **核验行为的发生证据：**通过监控被试是否打开证据材料、是否点击对照核查、在关键数据错漏处的鼠标停留时间，来获取个体是否启动元认知监控的直接证据。
2. **决策质量的修改证据：**精确比对 AI 初稿、被试修改稿与证据材料三者之间的文本差异，提取关键错漏纠正率与合规转写质量，作为其监督与合规能力的直接绩效指标。
3. **认知成本的控制证据：**记录精力点数的递减时序，计算被试在不同难度题目上的点数分配轨迹。

通过这套操作证据链，系统后台能够自动将这些多源交互行为数据，按照 2.2.4 节设计的算法模型（如 RES 效率公式、Rubric 判定矩阵）进行多维提炼，最终生成具备高可解释性的心理测量指标。

针对问题四，研究将通过**受控生成式 AI 交互机制**控制大语言模型输出的稳定性与可比性，从而解决生成式 AI 天然随机性与心理测量标准化要求之间的矛盾。由于大语言模型具有概率生成特征，其输出可能受到随机采样与上下文波动影响，从而带来测量条件不一致的问题(Bender et al., 2021)。与传统静态脚本不同，本研究中的 AI 并非预设固定文本，而是真实参与测验过程的人机协作对象。系统将在严格控制条件下调用大语言模型（如 GPT、Claude 或通义千问），使 AI 能够动态生成任务初稿并对受测者行为进行反馈，从而提升测验的人机交互真实性与生态效度。同时，研究通过多层参数锁定与输出约束机制，确保不同被试面对的是标准化、可复现的测验条件。

首先，在任务初稿生成阶段，系统会**预先固定每道题的背景材料、正确与错误逻辑分支以及关键风险点**。AI 根据题目类型实时生成初稿文本。在正确情境中，AI 会生成整体正确、但仍可优化修改的业务文本；在错误情境中，则会按照预设逻辑故意引入错误，例如混淆关键指标、错误引用数据或使用不合规表达。这样的设计能够使受测者真正面对“AI 可能对也可能错”的真实协作环境。

其次，为保证测量结果的标准化与跨个体可比性，研究将**严格控制模型生成参数**。系统调用 API 时，将温度参数（temperature）固定为 0，并锁定随机种子（seed），确保相同题目在不同被

试间生成一致的 AI 初稿。同时，系统还会固定提示词结构与输出模板，避免 AI 因表达差异引入额外测量误差。

再次，AI 不仅用于生成初稿，还将参与后续反馈过程。当受测者点击“对照核查”或“重新生成建议”等功能时，**AI 会结合受测者当前修改内容与证据材料进行回应**。例如，当受测者已经识别并修正关键错误时，AI 会返回“关键字段已修正，建议采用当前版本”等反馈；而当受测者直接采纳错误内容时，AI 则不会主动纠错，而是提示其“建议进一步与证据材料核对”。这种设计使 AI 成为动态交互中的回应者，而不仅是静态背景工具。

最后，为避免 AI 输出偏离测验目标，研究将**采用 few-shot 提示与固定回复模板**，对 AI 输出的长度、风格与表达范围进行限制。例如，限制其仅围绕当前任务进行回应，避免生成开放式建议或额外解释。所有提示词与参数设置都会在题库开发阶段经过多轮一致性测试，以确保 AI 输出满足心理测量对于稳定性和可复现性的要求。

总结来说，本研究引入真实生成式 AI 的重点，在于构建“AI 来源信息参与决策”的真实协作环境。因此，相较于生成内容的随机变化，测验更关注个体在面对 AI 建议时是否能够进行主动监督、风险识别与依赖校准。在这一前提下，对模型输出进行稳定化控制，是保证心理测量标准化与跨个体可比性的必要条件。

四、预期结果与成果提供形式

本研究预期在理论与实践两个层面产生具有创新意义的成果。

在理论层面，本研究有望验证“面向 AI 协作的个体监督校准与合规执行力”是一种可区分的行为能力结构，而非单纯的态度倾向。我们预计，不同个体在错误纠正率与合理采纳率之间将呈现显著差异，且盲信型与过疑型在行为轨迹上具有稳定特征。例如，盲信型个体可能在 AI 错误情境下较少展开证据材料并直接采纳初稿，而过疑型个体则可能在 AI 正确情境下过度修改并重复核查。若统计分析结果支持三维能力结构模型，则说明信任校准可以通过行为任务有效测量，从而为人机协作领域提供新的测量路径。

在实践层面，本研究将形成一套可运行的在线测验原型系统，包含六道标准化任务与完整 AI 分支库。系统可生成个体能力画像报告，呈现其在校准依赖、监督核验与合规边界执行方面的表现特征。该工具可直接应用于企业招聘筛查、面试辅助评估以及员工培训分层管理场景。在招聘实践中，组织可以通过测验结果识别潜在的盲信风险或过疑低效风险，从而优化用人决策；在培训情境中，则可针对能力短板开展针对性干预。

此外，本研究还将输出完整的评分模型说明文档与统计分析报告，为后续大规模推广与产品

化提供数据基础。若后续扩大样本规模并持续优化题库结构，该测验有潜力发展为标准化人机协作能力评估工具，为智能时代的人才测评体系提供新的组成部分。

综上所述，本研究不仅回应了当前人机信任校准领域缺乏行为测量工具的理论空白，也为组织管理实践中日益凸显的 AI 协作风险问题提供了可操作的解决路径。

五、特色与创新之处

(1) 策略+执行双层结构：真实任务结合 SJT

本测验突破传统单一 SJT 或自陈局限，融合了交互式任务（模块 A）与 SJT（模块 B）。两者形成“策略—执行”双层交叉验证结构，增强结构效度与解释力。模块 A 考察“真实执行中是否做到”，模块 B 考察“策略判断上是否知道”，两者互证可有效识别“知行分离”型个体。

(2) 交付成果与过程数据的多源融合

仅评估最终交付质量，难以区分“偶然正确”与“有效监督”。本测验引入全过程行为日志采集，实现对“监督行为是否真实发生”“是否在风险节点发生”的客观判定，避免仅凭结果推断的偏差。

(3) 校准性依赖能力的量化机制

采用正确/错误条件的随机对称设计，通过计算命中率、漏报率，实现信任校准连续谱的定位和受测者画像刻画。由于模块 A 交付物为开放文本，为保证评分稳定性与可复核性，本项目采用“客观字段半自动判分+Rubric 人工复核”的组合路径：关键数字/日期/条款编号等一致性可通过规则匹配实现半自动计分，证据边界表达与合规修正质量则依据统一 Rubric 由人工评分。正式施测时输出不仅包含分数，也包含可追溯证据（错在何处、是否核对、是否修正），用于面试追问与培训分层。

(4) “精力点数”机制的优势

“精力点数”将有限认知资源显性化，受测者在打开证据包或进行深度核查时需消耗点数，点数耗尽后无法继续深层核对，迫使受测者进行风险预判与资源优化配置。该机制模拟真实组织中的时间与注意力成本，有效防止“全面核查策略”带来的测量污染，使能力差异体现在“分配策略”而非“信息量堆积”上，构成测验结构上的创新。

精力点数消耗规则表			
动作（候选人可执行）	点数消耗	该动作带来的信息增量/测量意义	点数为0时是否可用
打开证据包全文（数据表/条款全文/邮件原文）	-2	获得原始证据锚点（数字/条款/日期/备注栏），支持关键核点对点核验	不可用
证据包一键定位到关键字段/条款（跳转到指定行列/条款号）	-1	定向核验，测“核验性价比判断”而非无脑翻找	不可用
AI：生成草稿	0	提供起草效率，不提升证据可靠性；鼓励使用但不直接加分	可用
AI：列出依据（标注来自证据包哪里）	-1	促使可追溯表达，暴露伪依据/错引用	不可用
AI：对照证据核查	-2	触发二次核验：正确题回引证据；错误题给矛盾/不确定信号	不可用
AI：标注不确定性（把超证据内容改保守）	-1	把推测拉回边界，减少编造/因果跳跃	不可用
AI：合规修正策略选择（A去标识化/B承诺降级/C引用标准口径）	-1	红线处理动作化，便于客观判分	不可用
AI：压缩字数/结构化输出（按结论-建议-风险）	0	提升交付效率，不等同于核验	可用
免费：查看证据包摘要（不含关键数字/条款编号/敏感字段）	0	防止纯盲作，同时保留“锚点需付费核验”的机制	可用

图 6 精力点数消耗规则表

(5) 合规边界嵌入式设计

合规风险并非显性违规，而是嵌入任务情境中的隐蔽红线与边界模糊，这更贴近真实组织风险结构，增强了测验在招聘筛选与风险预防中的实际应用价值。例如，某题中 AI 生成的客户回复包含“我们一定会在三日内解决”的承诺，受测者需识别“一定”属于越权表达并改为“我们会尽快处理”。

(6) 真实 AI 参与

本研究引入受控生成式 AI 技术，让 AI 真正参与测验全流程——动态生成初稿、响应被试操作、参与评分过程，实现了“人机协作的真实交互”。与传统静态脚本模拟不同，本测验中的 AI 并不是提前预设好的 AI 回答，而是真正在场的协作伙伴。通过锁定模型参数(temperature=0, seed 固定)，在保证生态效度的同时实现标准化测量。这使得测验不是“测 AI 背后的人”，而是真正“测人与 AI 的动态关系”。

并且，在评分环节引入 AI 技术，构建“AI 辅助初评+人工 Rubric 复核”的双轨并行模式。AI 负责客观指标识别(关键字段一致性、明显合规风险等)，人工负责主观质量判断(证据边界表达、

合规修正合理性等)。这一创新不仅提升评分效率，也使 AI 在测验中实现了“被测对象—互动伙伴—评估工具”的三重角色，充分体现人机融合特征。

六、成本预算

1 被试费用

测验开发需开展多轮施测以检验题目质量与信效度。预测试阶段招募 10 名本科生参与界面调试与题目检验，按校内实验常见标准每人 30 元计算，共计 300 元。正式施测阶段为进行信效度检验与能力结构验证，需招募 50 名具有知识型岗位实习经历或求职经验的高年级本科生，确保样本代表性，每人 50 元（考虑任务时长 25 分钟），共计 2500 元。重测信度阶段从正式样本中随机抽取 20 人，间隔两周后邀请参与重测，每人 30 元，共计 600 元。以上通过校内实验被试库招募并借助学生志愿者资源，有效控制成本，被试费用总计 3400 元。

2 模型调用费用

本测验采用受控生成式 AI 机制，每道题在被试作答时实时调用大模型 API 生成初稿与反馈。预估正式施测阶段 50 名被试×6 道模块 A 题目×平均 3 次 AI 调用(初稿生成 1 次+对照核查/重新生成 2 次)=900 次；另外，题库开发与评分规则验证阶段需调用 AI 辅助生成题目文本、干扰选项及多个版本供专家组筛选，预估约 700 次；评分阶段 50 名被试×6 道题×AI 初评 1 次=300 次。合计 1900 次调用。

按当前市场主流模型(如 GPT-3.5-turbo 或通义千问)均价每千 token 约 0.24 元、每次调用平均消耗 2000 token 估算，单次调用成本约 0.48 元，总计 912 元。

为控制成本，题库开发阶段可优先使用开源模型或教育优惠 API(如 OpenAI 教育折扣可减免 50%)；正式施测阶段采用缓存机制，对相同输入复用历史输出，减少重复调用；评分阶段采用批量调用模式享受价格优惠。实际支出预计可控制在 650 元以内。

3 基础云服务费用

部署在线测验系统需租用云服务器、配置数据库及域名。采用国内主流云服务商轻量应用服务器（1 核 2GB 内存、3Mbps 带宽），月租 80 元，项目周期按 2 个月计（开发调试 1 个月、施测与数据采集 1 个月），共计 160 元。申请廉价域名（如.top）首年费用 30 元，SSL 证书使用免费版。对象存储用于存放被试提交的文本答案及行为日志，预估数据量 20GB 以内，2 个月存储费用约 30 元；数据库基础版费用约 20 元。另预留 30 元用于突发流量或备份需求。充分利用学生认证优惠与免费资源，基础云服务费用总计 270 元。

以上三项预算总计 4320 元，各项支出均有明确依据且通过技术优化实现成本控制。

七、参考文献

- Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 610 – 623. <https://doi.org/10.1145/3442188.3445922>
- Cui, Z., Zhuang, X., Lee, S. C., Lee, J., Li, X., & Itoh, M. (2025). Developing and validating a Chinese human-automation trust scale: Advancing trust measurement of emerging automation in sustainable ergonomics. *Applied Ergonomics*, 125, Article 104477. <https://doi.org/10.1016/j.apergo.2025.104477>
- Dietvorst, B. J., Simmons, J. P., & Massey, C. (2015). Algorithm aversion: People erroneously avoid algorithms after seeing them err. *Journal of Experimental Psychology: General*, 144(1), 114 – 126. <https://doi.org/10.1037/xge0000033>
- Huang, X., & Li, Y. (2024). Trust dampening and trust promoting: A dual-pathway of trust calibration in human-robot interaction. *Advances in Psychological Science*, 32(3), 527 – 542. <https://doi.org/10.3724/SP.J.1042.2024.00527>
- Lee, J. D., & See, K. A. (2004). Trust in automation: Designing for appropriate reliance. *Human Factors*, 46(1), 50 – 80. https://doi.org/10.1518/hfes.46.1.50_30392
- McDaniel, M. A., Hartman, N. S., Whetzel, D. L., & Grubb, W. L. (2007). Situational judgment tests, response instructions, and validity: A meta-analysis. *Personnel Psychology*, 60(1), 63 – 91. <https://doi.org/10.1111/j.1744-6570.2007.00065.x>
- McKinsey & Company. (2023a). *The economic potential of generative AI: The next productivity frontier*. <https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/the-economic-potential-of-generative-ai-the-next-productivity-frontier>
- McKinsey & Company. (2023b). *The state of AI in 2023: Generative AI ’ s breakout year*. <https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/the-state-of-ai-in-2023-generative-ais-breakout-year>
- Mosier, K. L., & Skitka, L. J. (1996). Human decision makers and automated decision aids: Made for each other? In R. Parasuraman & M. Mouloua (Eds.), *Automation and human performance: Theory and*

applications (pp. 201 – 220). Lawrence Erlbaum Associates.

Nelson, T. O., & Narens, L. (1990). Metamemory: A theoretical framework and new findings. In G. H. Bower (Ed.), *The psychology of learning and motivation* (Vol. 26, pp. 125 – 173). Academic Press.

[https://doi.org/10.1016/S0079-7421\(08\)60053-5](https://doi.org/10.1016/S0079-7421(08)60053-5)

Sackett, P. R., Zedeck, S., & Fogli, L. (1988). Relations between measures of typical and maximum job performance. *Journal of Applied Psychology*, 73(3), 482 – 486.

<https://doi.org/10.1037/0021-9010.73.3.482>

Tabassi, E. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)* (NIST Trustworthy and Responsible AI). National Institute of Standards and Technology.

<https://doi.org/10.6028/NIST.AI.100-1>